

Plateforme SpecGeny - Guide Général



Table des Matières

- 1. [Vue d'Ensemble](#)
 - 2. [Contexte et Problématique](#)
 - 3. [Solution Proposée](#)
 - 4. [Objectifs Stratégiques](#)
 - 5. [Architecture et Conception](#)
 - 6. [Fonctionnalités MVP](#)
 - 7. [Fonctionnalités Futures](#)
 - 8. [Technologies](#)
 - 9. [Modèle d'Affaires](#)
 - 10. [Roadmap](#)
 - 11. [Métriques de Succès](#)
 - 12. [Équipe et Rôles](#)
-



Vue d'Ensemble

SpecGeny est une plateforme agentique intelligente qui automatise la génération de documents de spécifications techniques à partir de fichiers projets existants.

Vision

Transformer la création de spécifications techniques d'un processus manuel, chronophage et sujet aux erreurs en un workflow assisté par IA, rapide et structuré.

Proposition de Valeur

- **Gain de temps** : Réduction de 70-80% du temps de rédaction de spécifications
- **Qualité constante** : Spécifications structurées selon des templates standardisés
- **Accessibilité** : Permet aux non-techniques de générer des specs professionnelles
- **Human-in-the-Loop** : Validation humaine à chaque étape critique pour garantir la précision

Cible Initiale

MVP Focus : UiPath Process Design Documents (PDD)

Génération automatique de PDDs pour les projets d'automatisation RPA.



Contexte et Problématique

Problème Identifié

- 1. **Coût élevé de création manuelle**
 - 5-15 heures pour rédiger une spécification complète
 - Nécessite expertise technique ET rédactionnelle

- Processus répétitif et peu valorisant

2. Qualité inconsistante

- Manque de standardisation entre équipes
- Oublis de sections critiques
- Désalignement entre documentation et implémentation

3. Barrière à l'entrée

- Les équipes non-techniques dépendent d'architectes/leads
- Goulot d'étranglement dans la phase de conception
- Documentation obsolète avant même l'implémentation

Opportunité

L'émergence de LLMs multi-modaux (GPT-4, Claude Sonnet 4.5) permet d'automatiser l'analyse de fichiers projets et la génération de contenu structuré de qualité professionnelle.

Inspiration

Le projet s'inspire de [github/spec-kit](https://github.com/spec-kit/spec-kit), un toolkit de "Spec-Driven Development" qui structure la création de spécifications en phases distinctes (/specify, /plan, /tasks, /implement).


Notre différenciation : Automatiser les phases humaines (analyse de contexte, extraction d'intent) via un système multi-agents.



Solution Proposée

Workflow Utilisateur (UX)





Principe Clé : Multi-Agent Backend

Le "magic agent" est en réalité un **orchestrateur de plusieurs agents spécialisés** :

- **Agent Ingestion** : Traite les fichiers (OCR, parsing, embeddings)
- **Agent Analyzer** : Extrait les insights (architecture, user stories, décisions)
- **Agent Mapper** : Mappe les insights aux sections du template
- **Agent Generator** : Rédige le contenu structuré
- **Agent Validator** : Vérifie la cohérence et complétude

Objectifs Stratégiques

Court Terme (MVP - 3 mois)

- 1. **Validation du concept** : Prouver la faisabilité technique avec UiPath PDDs
- 2. **Acquisition de 10-20 beta users** (équipes RPA internes/externes)
- 3. **Temps de génération < 5 minutes** pour un PDD complet
- 4. **Taux de satisfaction > 80%** sur la qualité du draft

Moyen Terme (6-12 mois)

- 1. **Extension à 3-5 types de templates** (PRD, Tech Spec, API Docs)
- 2. **100+ utilisateurs actifs**
- 3. **Intégrations** : Jira, Confluence, GitHub, GitLab
- 4. **Monétisation** : Lancement du modèle consumption-based


Long Terme (12-24 mois)

- 1. **Plateforme SaaS multi-tenant**
 - 2. **Marketplace de templates** (communautaire)
 - 3. **Agent autonome** : Génération sans review pour cas simples
 - 4. **Enterprise features** : SSO, on-premise, custom LLMs
-

Architecture et Conception

Architecture Haut Niveau





Décisions Techniques Clés

- 1. **Framework Multi-Agent** : LangGraph (plus flexible pour workflows complexes)
- 2. **LLM Principal** : Claude Sonnet 4.5 (meilleur pour génération structurée)
- 3. **Vector DB** : Pinecone (pour recherche sémantique dans fichiers)
- 4. **Frontend** : React + shadcn/ui (design moderne, accessibilité)
- 5. **Storage** : PostgreSQL (métadonnées) + S3 (fichiers binaires)

Flux de Données



User Upload → Object Storage (S3)

→ Ingestion Agent → Chunks → Vector Store

→ Analyze Agent → Insights → PostgreSQL

→ Mapper Agent → Block Mappings → PostgreSQL

→ Generator Agent → Draft Spec → PostgreSQL

→ Review UI → User Edits → Refinement Loop

→ Export Service → Final Document (PDF/MD/DOCX)



Fonctionnalités MVP

Phase A : Gestion des Templates

MVP-A1 : Template Pré-Configuré UiPath PDD

- ☒ Template PDD hardcodé avec sections standards
- ☒ Sections : Overview, Process Flow, Decision Points, Exception Handling, Test Scenarios
- ☐ Pas de création custom de templates (future feature)

MVP-A2 : Instruction Blocks

- ☒ Backend génère automatiquement les prompts d'extraction pour chaque section
- ☒ Exemple : "Extract all decision points from workflow diagrams"
- ☒ Stockage en base de données relationnelle

Phase B : Ingestion et Analyse

MVP-B1 : Upload Multi-Format

- ☒ Support de formats : .docx, .pdf, .png/.jpg (flowcharts), .txt, .md
- ☒ Limite : 10 fichiers max, 50 MB total
- ☐ Pas de .xlsx, .pptx, .figma (future)

MVP-B2 : Multi-Modal Processing

- ☒ OCR pour images (via Claude Vision ou Google Document AI)
- ☒ Embeddings textuels (OpenAI Ada-002 ou Voyage AI)
- ☒ Parsing de documents structurés (python-docx, PyPDF2)
- ☐ Pas d'AST parsing de code (future)

MVP-B3 : Analyse Agentique

- ☒ Agent Analyzer utilise RAG pour extraire :
 - User stories implicites
 - Décisions d'architecture
 - Points de décision métier
 - Scénarios d'exception
- ☒ Scoring de confiance par insight (0-100%)

Phase C : Génération et Validation

MVP-C1 : Génération Draft

-  Agent Generator produit un document Markdown structuré
-  Chaque section marquée avec score de confiance
-  Sections incomplètes signalées explicitement

MVP-C2 : Interface de Review (Human-in-the-Loop)

-  UI affiche le draft avec surlignage :
 -  Vert : Confiance > 80%
 -  Jaune : Confiance 50-80%
 -  Rouge : Confiance < 50%
-  Éditeur de texte enrichi pour modifications inline
-  Bouton "Régénérer cette section" pour re-prompt l'agent
-  Pas de collaboration multi-utilisateurs (future)

MVP-C3 : Boucle de Raffinement

-  Après édition, agent réanalyse les changements
-  Max 2 itérations de raffinement (pour contrôler coûts API)
-  Diff visualisé entre versions

Phase D : Export

MVP-D1 : Export Formats

-  Markdown (natif)
-  PDF (via Pandoc ou Playwright)
-  Pas de Word (.docx) dans MVP (future)

MVP-D2 : Versioning Basique

-  Historique des drafts (timestampé)
-  Possibilité de rollback à version précédente
-  Pas de Git integration (future)

Fonctionnalités Transverses

MVP-T1 : Authentification et Sécurité

-  Auth simple (email + password via Supabase Auth)
-  Isolation des données par utilisateur
-  Pas de SSO / SAML (future)

MVP-T2 : Monitoring et Observabilité

-  Logs structurés (Winston / Pino)
 -  Tracking du temps de génération par phase
 -  Alertes sur erreurs API LLM
-



Fonctionnalités Futures

Version 1.1 (Post-MVP)

F1.1 : Templates Additionnels

- Product Requirements Document (PRD)
- Technical Design Document (TDD)
- API Documentation

F1.2 : Customisation de Templates

- UI pour créer/éditer des templates
- Marketplace communautaire de templates

F1.3 : Support de Fichiers Avancés

- .xlsx avec parsing de tables
- .pptx avec extraction de diagrammes
- Liens Figma (via API)

Version 1.5

F1.5.1 : Collaboration

- Multi-utilisateurs sur un même spec
- Système de commentaires inline
- Approval workflow

F1.5.2 : Intégrations

- Jira : Import d'issues comme input
- Confluence : Export direct en page
- GitHub : Sync avec repository

Version 2.0

F2.0.1 : Agent Autonome

- Mode "auto" sans review pour specs simples
- Détection automatique du type de projet
- Génération de user stories à partir de zéro

F2.0.2 : Enterprise Features

- SSO (Okta, Azure AD)
- On-premise deployment
- Custom LLM (modèles propriétaires)
- Audit trails complets

F2.0.3 : Advanced Analytics

- Benchmarking de qualité de specs
- Suggestions d'amélioration continues
- Prédiction du temps d'implémentation

Technologies

Stack MVP

Couche	Technologie	Justification
Frontend	React 18 + TypeScript	Écosystème mature, shadcn/ui
UI Components	shadcn/ui + Tailwind CSS	Design moderne, accessible
Backend	FastAPI (Python 3.11+)	Async natif, intégration LLM facile
Agent Framework	LangGraph	Workflow multi-agents, debuggabilité
LLM Provider	Anthropic Claude Sonnet 4.5	Meilleur pour génération structurée
Vector DB	Pinecone	Managed, scalable
Database	PostgreSQL 15	Relationnel + JSONB pour flexibilité
File Storage	AWS S3 / MinIO	Object storage standard
Auth	Supabase Auth	Gratuit, facile à intégrer
Hosting	Vercel (Frontend) + Railway (Backend)	Deploy simple, CI/CD intégré
Monitoring	Sentry + Posthog	Erreurs + analytics utilisateurs

Alternatives Considérées

- **LlamaIndex vs LangGraph** : LangGraph choisi pour plus de contrôle sur workflow
- **OpenAI GPT-4 vs Claude** : Claude préféré pour meilleure suivre d'instructions structurées
- **Chroma vs Pinecone** : Pinecone pour éviter self-hosting en MVP

Modèle d'Affaires

Stratégie de Monétisation (Post-MVP)

Modèle Consumption-Based (Pay-as-you-go)

Métrique	Prix	Justification
Génération de spec	5-10€ / spec	Aligné sur coût API (~2-3€) + marge
Stockage	0.50€ / GB / mois	Coût S3 + buffer
Raffinement (iterations)	1€ / itération	Encourage validation humaine efficace

Tiers (Future)

1. **Free Tier**
 - 3 specs / mois
 - Templates standards uniquement
 - Export Markdown seulement
2. **Pro Tier** (29€ / mois)
 - 20 specs / mois
 - Templates custom
 - Tous exports (PDF, Word)
 - Historique 90 jours
3. **Enterprise Tier** (Custom)
 - Specs illimitées
 - SSO / On-premise
 - Support prioritaire
 - SLA 99.9%

Coûts Estimés (MVP)

Poste	Coût Mensuel
Claude API (1000 specs @ 3€)	3 000€
Pinecone (Starter)	70€
AWS S3 + RDS	150€
Vercel + Railway	50€
Monitoring (Sentry + Posthog)	0€ (free tiers)
Total	~3 270€

Break-even : ~400 specs payantes / mois à 8€ pièce.



Roadmap

Phase 0 : Préparation (2 semaines)

- ☒ Validation du concept (ce document)
- ☐ Recherche utilisateurs (interviews 5-10 RPA teams)
- ☐ Setup infrastructure (repos, CI/CD, staging env)
- ☐ Design UI mockups (Figma)

Phase 1 : MVP Core (6 semaines)

Semaine 1-2 : Backend Foundation

- ☐ Setup FastAPI + PostgreSQL + S3
- ☐ Auth Supabase intégrée
- ☐ Template PDD hardcodé en DB

Semaine 3-4 : Agent Pipeline

- ☐ Ingestion agent (OCR + embeddings)
- ☐ Analyzer agent (RAG + prompt engineering)
- ☐ Generator agent (structured output)
- ☐ LangGraph orchestration

Semaine 5-6 : Frontend & Integration

- ☐ UI upload + template selection
- ☐ Review interface (color-coded sections)
- ☐ Export pipeline (MD + PDF)
- ☐ End-to-end testing

Phase 2 : Beta & Iteration (4 semaines)

Semaine 7-8 : Beta Launch

- ☐ Onboarding de 10-15 beta users
- ☐ Collecte feedback structuré
- ☐ Bug fixes prioritaires

Semaine 9-10 : Refinement

- ☐ Amélioration des prompts (based on feedback)
- ☐ Optimisation des coûts API
- ☐ Ajout de métriques utilisateur

Phase 3 : V1.0 Public (2 semaines)

Semaine 11-12 : Production Ready

- ☐ Monitoring avancé (alertes, dashboards)
- ☐ Documentation utilisateur
- ☐ Landing page + marketing
- ☐ Launch 🚀

📊 Métriques de Succès

KPIs Techniques

Métrique	Target MVP	Mesure
Temps de génération	< 5 min	Median p50
Uptime	> 95%	30-day rolling
Taux de succès génération	> 90%	Specs complètes / total
Coût API par spec	< 3€	Moyenne mensuelle

KPIs Produit

Métrique	Target MVP	Target 6 mois
Beta users actifs	10-20	100+
Specs générées / mois	50-100	500+
Taux de satisfaction	> 80%	> 85%
Net Promoter Score (NPS)	> 40	> 50
Temps gagné vs manuel	> 60%	> 70%

KPIs Business (Post-MVP)

Métrique	Target 6 mois	Target 12 mois
MRR (Monthly Recurring Revenue)	2 000€	10 000€
Paying customers	20	100
Customer Acquisition Cost (CAC)	< 100€	< 50€
Lifetime Value (LTV)	> 300€	> 600€

👥 Équipe et Rôles

MVP Team (Core)

Tech Lead / Architect (Vous)

- Responsable architecture multi-agents
- Code review et décisions techniques
- Gestion roadmap technique

Backend Engineer (1 FTE)

- Développement API FastAPI
- Intégration LangGraph + Claude API
- Database design et migrations

Frontend Engineer (1 FTE)

- React UI avec shadcn/ui
- Review interface (éditeur WYSIWYG)
- Intégration API backend

UX/UI Designer (0.5 FTE)

- Mockups Figma
- User testing et itérations
- Design system

[Optionnel] ML/Prompt Engineer (0.5 FTE)

- Optimisation des prompts LLM
- Fine-tuning de retrieval strategy
- A/B testing de techniques RAG

Compétences Requises

- **Backend** : Python, FastAPI, PostgreSQL, S3, LangChain/LangGraph
 - **Frontend** : React, TypeScript, Tailwind CSS, Markdown editing
 - **AI/ML** : Prompt engineering, embeddings, RAG, vector DBs
 - **DevOps** : Docker, CI/CD (GitHub Actions), monitoring
-

Ressources et Références

Inspiration Technique

- [github/spec-kit](#) - Spec-Driven Development toolkit
- [LangGraph](#) - Multi-agent orchestration
- [LlamaIndex](#) - RAG framework

Documentation LLM

- [Anthropic Claude API](#)
- [OpenAI Embeddings](#)

UI/UX

- [shadcn/ui](#) - Component library
 - [Radix UI](#) - Accessible primitives
-



Prochaines Étapes

Actions Immédiates (Cette Semaine)

- 1. ☒ Valider ce document avec stakeholders
- 2. ☐ Recruter interviews utilisateurs (5 équipes RPA)
- 3. ☐ Créer maquettes Figma (flow complet)
- 4. ☐ Setup repository GitHub (monorepo Turborepo ?)
- 5. ☐ Définir stack technique finale (LangGraph vs LlamaIndex decision)

Décisions à Prendre

- **Choix du LLM** : Claude Sonnet 4.5 vs GPT-4 Turbo (benchmark à faire)
- **Hosting backend** : Railway vs Render vs AWS ECS
- **Vector DB** : Pinecone vs Qdrant (managed vs self-hosted)



Contact et Suivi

Project Lead : [Votre Nom] **Email** : votre.email@example.com **Slack Channel** : #specgeny-dev **Notion Board** : [\[Lien vers board projet\]](#)

Cadence de Review

- **Daily Standups** : 9h30 (15 min)
- **Weekly Sprint Review** : Vendredi 14h
- **Monthly Stakeholder Update** : Premier lundi du mois



Notes de Fin

Ce document est un **living document** qui évoluera au fur et à mesure du développement.

Version : 1.0 (28 Octobre 2025) **Dernière mise à jour** : [Date] **Prochaine révision** : Après Phase 0 (fin Novembre 2025)

SpecGeny - Générez des spécifications, pas de la frustration. 🚀